# Introdução ao ambiente SDUMONT/SLURM

Escola Santos Dumont
22 de janeiro 2024
LNCC
evento remoto online



# A máquina

Mobull - solução para datacenter baseada em containers.

Plug & Boot

2 containers com 22 racks 42U



# A máquina





Cluster de propósito geral

3 tipos de nodes:

- thin nodes
- hybrid nodes
- fat-node



#### Thin nodes (B710)

- 7 racks completos (504 nós computacionais)
- 2 nós computacionais por blade
- Configuração
  - 2x Intel Xeon E5-2695v2 (12c, 2.4Ghz)
  - 64 GB DDR3 RAM (8x 8GB DIMM)
  - o 1x 120GB SSD disk
  - 1x Infiniband FDR ConnectX3
  - 1x GbE







#### Thin nodes (Bull Sequana) - Machine Learning/Deep Learning

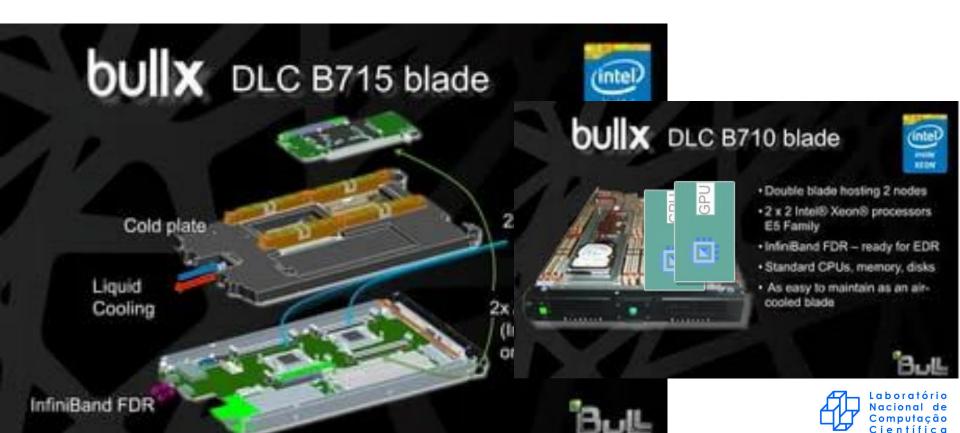
- 1 nó computacional
- Configuração
  - 2x Intel Skylake GOLD 6148, 2,4Ghz (20c)
  - o 384 GB DDR4
  - 4x Infiniband EDR 100Gbps
  - 8x NVidia V100 com NVLink



#### Hybrid nodes (B715)

- 7 racks completos (252 nós computacionais e 504 aceleradores)
- 198 nodes e 396 nVidia K40
- 54 nodes e 108 Intel Phi 7120P -> nodes CPU

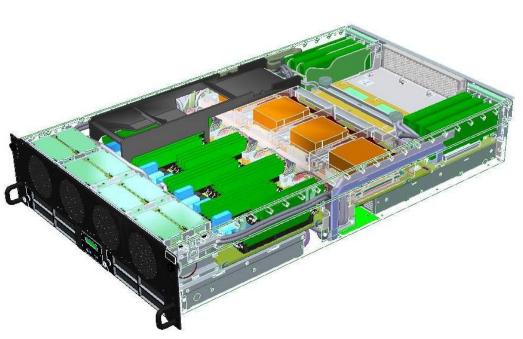




#### Fat-node (S6130)

- 16x Intel Ivy Bridge E7 2870v2 15c 2.3Ghz
- 6TB DDR3 RAM
- 1x 120GB SSD disk
- 1x Infiniband FDR ConnectX3
- 1x GbE









Escola Santos Dumont - 22 de Janeiro de 2024

#### Login nodes

- 4x bullx R423-E3
- Linux Virtual Server (LVS)
- Cada login node possui:
  - o 2x E5-2695v2 12c, 2.4GHz
  - 128 GB DDR3@1866RAM
  - o 2x 500GB 7.2krpm SATA2 RAID1
  - 1x GbE network port
  - 1x IB FDR network port
  - 1x Ethernet BMC network port
  - 2x 10GbE network ports



#### Armazenamento

- Lustre Seagate ClusterStor 9000 /scratch
  - Total 1,7 Petabytes
- DellEMC Isilon /prj
  - Total 650 Terabytes



## Estrutura de diretórios

#### Diretório home (\$HOME):

- NFS Acessível apenas nos login nodes
- /prj/PROJETO/login.name

#### Diretório de scratch (\$SCRATCH):

- Lustre Acessível a todos os nodes do cluster
- /scratch/PROJETO/login.name



# Desempenho

• GPU - 456,8 TFlop/s

• PHI - 363,2 TFlop/s

• CPU - 321,2 TFlop/s

• Total - 1.141,2 TFlop/s



TOP 500	Total	GPU	PHI	CPU
Jun/15	55	145	177	207
Nov/15	63	200	265	310
Jun/16	75	265	364	433
Nov/16	91	364	476	
Jun/17	107	472		
Nov/17	128			
Jun/18	192			
Nov/18	316			

https://www.top500.org



Expansão SDumont - 2018/2019

1 Célula Sequana X1000 CPU

o 82 Blades X1120 - 384 GB

12 Blades X1120 - 768 GB

282 nós computacionais

2x Intel CascadeLake Gold 6252 (24c)

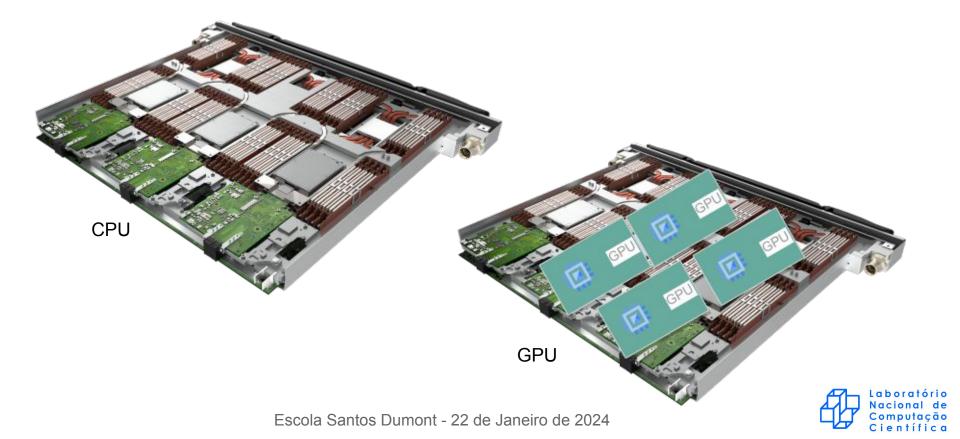
1 Célula Sequena X1000 GPU

- 94 Blades X1125 384 GB
- 1 nó computacional e 4 aceleradores
   NVIDIA Volta V100 GPU por blade
- 2x Intel CascadeLake Gold 6252 (24c)





# Expansão SDumont - 2018/2019



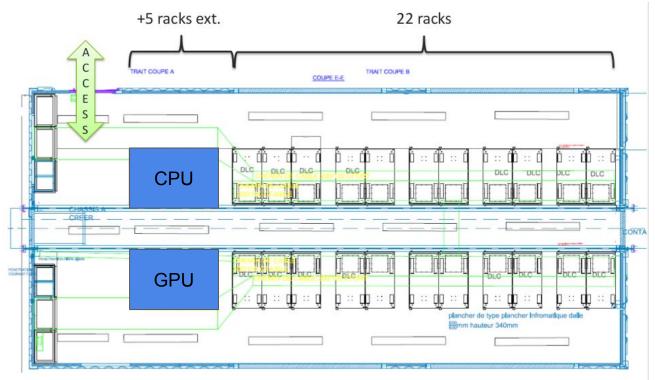
# Expansão SDumont

#### Login nodes

- 4x Login nodes:
  - o 2x Intel Xeon Gold 6152 22c, 2.1GHz
  - 756 GB DDR3@1866RAM
  - 2x SSD MZ7LM960
  - 1x GbE network port
  - 2x IB FDR network port
  - 2x 10GbE network ports



# Expansão SDumont





## Desempenho

#### Novembro 2019

Brazil

276

Laboratório Nacional de S Computação Científica -

Atos

Santos Dumont (SDumont) 33,856

- Bull Sequana X1000, Xeon Gold 6252 24C 2.1GHz, Mellanox InfiniBand EDR, NVIDIA Tesla V100 SXM2 3.856 1.849.0

Cores

Rmax

(PFlop/s)

2,727.0

Rpeak

(PFlop/s)

TOP 500
The List.

#### Junho 2020

Cores	Rmax (PFlop/s)	Rpeak (PFlop/s)	
33,856	1,849.0	2,727.0	

240

Santos Dumont (SDumont) - Bull Sequana X1000, Xeon Gold 6252 24C 2.1GHz, Mellanox InfiniBand EDR, NVIDIA Tesla V100 SXM2, Atos

Laboratório Nacional de Computação Científica

Brazil

#### Novembro 2020

Santos Dumont (SDumont) - Bull Sequana X1000, Xeon Gold 6252 24C 2.1GHz, Mellanox InfiniBand EDR, NVIDIA Tesla V100

SXM2, Atos

Laboratório Nacional de Computação Científica

Brazil

Cores	Rmax (PFlop/s)	Rpeak (PFlop/s)		
33,856	1,849.0	2,727.0		



## Desempenho

Novembro 2022

Cores

33,856

Rmax (PFlop/s)

1.85

Rpeak (PFlop/s)

2.73

PF(op/s)

462 San

Santos Dumont (SDumont) - Bull Sequana X1000, Xeon Gold 6252 24C 2.1GHz, Mellanox InfiniBand EDR, NVIDIA

Tesla V100 SXM2, Atos

2.4GHz, 25G Ethernet, ACTION

United States

MIT Lincoln Laboratory Supercomputing Center

Laboratório Nacional de Computação Científica

Brazil

#### Novembro 2023

L	Frontier - HPE Cray EX235a, AMD Optimized 3rd	8,699,904	1,194.00	1,679.82	22,70
	Generation EPYC 64C 2GHz, AMD Instinct MI250X,				
	Slingshot-11, HPE				
	DOE/SC/Oak Ridge National Laboratory				
	United States				

Escola Santos Dumont - 22 de Janeiro de 2024

Laboratório Nacional de Computação Científica

The List.

## Filas

Filas SDBASE (24 núcleos/nó)	Wall-clock	Nodes	Núcleos	Execução	Na fila
cpu_dev	20 min	1-4	1-96	1	1
nvidia_dev	20 min	1-4	1-96	1	1

Filas SEQUANA (48 núcleos/nó)	Wall-clock	Nodes	Núcleos	Execução	Na fila
sequana_cpu_dev	20 min	1-4	1-192	1	1
sequana_gpu_dev	20 min	1-4	1-192	1	1



## Módulos de ambiente

module avail : Lista todos as aplicações (módulos) disponíveis

module whatis/help <app>/<versão> : Exibe uma ajuda sobre a aplicação (módulo)

module load <app>/<versão> : Carrega o módulo (já carrega as dependências)

module unload <app>/<versão> : Descarrega o módulo

module list : Lista os módulos carregados

#### **Intel Parallel Studio**

source /scratch/app/modulos/intel-psxe-20[16|17|18|19|20].sh (também tem módulo = intel\_psxe/<versão>)

Escola Santos Dumont - 22 de Janeiro de 2024



# Compiladores

#### **GNU**

Versões: 4.8.5, 6.5, 7.4, 8.3, 9.3, 10.2 e 11.1

#### INTEL

Versões: 2016, 2017, 2018, 2019 e 2020

#### PGI

Versão 2016.5 e 2019.10 (Community) - **Expirado**! Possível instalar novas versões, caso necessário.



# Implementações MPI

OpenMPI (Bull)

Versão 4.0.3 - Implementação MPI compilada pela Bull

#### **OpenMPI**

Versões: 1.8.6, 1.10.7, 2.0.x, 2.1.x, 3.1.x, 4.0.x, 4.1.x e 5.0.0

Intel MPI

Versões 5.1, 2016, 2017, 2018, 2019 e 2020



## Slurm

Versão 20.11.8

Onde encontrar referências?

http://sdumont.lncc.br/

https://slurm.schedmd.com/archive/slurm-20.11.8

Política de escalonamento

Backfill: prioridade, tempo na fila, recursos solicitados e etc.



## Acesso

Somente quem já possuir conta no SDumont poderá acessar o ambiente.

\$ ssh meu.login@login.sdumont.lncc.br

Não serão distribuídas credenciais "genéricas".



## SLURM: comandos básicos

- sacctmgr: lista acesso às filas
- sinfo: visualiza informação sobre os nós e partições do SLURM
- squeue: visualiza informação sobre o status dos jobs e escalonamento
- srun: alocação de recursos e distribuição de tarefas
- scontrol: ferramenta para visualizar e/ou modificar o estado de um job
- salloc: obtém uma alocação para o job
- sbatch: submete um script para alocação em uma partição do SLURM
- scancel: cancela um job
- sacct: mostra informação de jobs já submetidos
- sreport: mostra os recursos consumidos



## sacctmgr: lista acesso às filas

#### Lista as filas que o usuário tem acesso (entre outras coisas):

\$ sacctmgr list user \$USER -s format=account,partition%30,maxjobs,maxnodes,maxcpus,maxsubmit,maxwall

Account	Partition	MaxJobs	MaxNodes	MaxCPUs	MaxSubmit	MaxWall
			1.5	720		4 00 00 00
xpto	sequana_gpu_shared	4	15	720	24	4-00:00:00
xpto	sequana_gpu_dev	1	4	192	1	00:20:00
xpto	nvidia_small	4	20	480	24	01:00:00
xpto	nvidia_long	2	10	240	4	31-00:00:00
xpto	nvidia_scal	1	128	3072	8	18:00:00
xpto	nvidia_dev	1	4	96	1	00:20:00
xpto	nvidia	4	50	1200	24	2-00:00:00
xpto	sequana_cpu_shared	4	50	2400	24	4-00:00:00
xpto	sequana_cpu_dev	1	4	192	1	00:20:00
xpto	cpu_shared	16	20	480	96	3-00:00:00
xpto	cpu_small	16	20	480	96	3-00:00:00
xpto	cpu_long	3	10	240	18	31-00:00:00
xpto	cpu_scal	1	128	3072	8	18:00:00
xpto	cpu_dev	1	4	96	1	00:20:00
xpto	cpu	4	50	1200	24	4-00:00:00

<sup>\*1</sup>Lista resumida: sacctmgr list user \$USER -s format=partition%30



<sup>\*2</sup>A variável de ambiente "\$USER" possui o "login" do próprio usuário executando o comando.

## SLURM: comandos básicos

- sacctmgr: lista acesso às filas
- sinfo: visualiza informação sobre os nós e partições do SLURM
- **squeue:** visualiza informação sobre o status dos jobs e escalonamento
- **srun**: alocação de recursos e distribuição de tarefas
- scontrol: ferramenta para visualizar e/ou modificar o estado de um job
- salloc: obtém uma alocação para o job
- sbatch: submete um script para alocação em uma partição do SLURM
- scancel: cancela um job
- sacct: mostra informação de jobs já submetidos
- sreport: mostra os recursos consumidos



#### sinfo

```
$ sinfo -s
```

PARTITION cpu_dev nvidia_dev	AVAIL up up	TIMELIMIT infinite infinite	NODES (A/I/O/T) 124/180/38/342 182/11/0/193	NODELIST sdumont[1000-1009,,1414-1503] sdumont[3000-3035,,3190-3197]
sequana_cpu_dev	up	20:00	61/51/0/112	sdumont[6068-6084,,6279-6287]
sequana_gpu_dev	up	20:00	31/10/1/42	sdumont[8044-8055,,8093-8095]



#### sinfo

```
$ sinfo -s
```

```
PARTITION
                AVAIL
                       TIMELIMIT
                                    NODES (A/I/O/T)
                                                    NODELIST
                                     350/229/7/586
cpu*
                        infinite
                                                    sdumont[1000-1503,3110-3159,5012-5043]
                   up
                                      119/71/2/192
                                                    sdumont[3006-3197]
nvidia
                        infinite
                   up
phi
                        infinite
                                        13/19/0/32
                                                    sdumont[5012-5043]
                   up
mesca2
                                           0/1/0/1
                                                    sdumont57
                        infinite
                   up
                                     350/229/7/586
cpu small
                        infinite
                                                    sdumont[1000-1503,3110-3159,5012-5043]
                   up
                                      119/71/2/192
nvidia small
                        infinite
                                                    sdumont[3006-3197]
                   up
                                     287/220/7/514
cpu dev
                        infinite
                                                    sdumont[1000-1503,5044-5053]
                   up
nvidia dev
                        infinite
                                      119/71/2/192
                                                    sdumont[3006-3197]
                   up
                                        13/19/0/32
                                                    sdumont[5012-5043]
phi dev
                        infinite
                   up
                                     350/229/7/586
cpu scal
                        infinite
                                                    sdumont[1000-1503,3110-3159,5012-5043]
                   up
                                     300/229/7/536
cpu long
                        infinite
                                                    sdumont[1000-1503,5012-5043]
                   up
nvidia scal
                        infinite
                                      119/71/2/192
                                                    sdumont[3006-3197]
                   up
nvidia long
                        infinite
                                      119/71/2/192
                                                    sdumont[3006-3197]
                   up
                                     419/328/9/756
                                                    sdumont[1000-1503,3000-3197,5000+5053] or a
all
                inact 2-00:00:00
```

Escola Santos Dumont - 22 de Janeiro de 2024

#### sinfo

Outras opções:

- -5
- --long
- --state
- -R



#### squeue

Outras opções

- -5
- -u (user)
- -A (account)
- -p



#### squeue

```
$ squeue
```

JOBID	PARTITION	NAME	USER	ST	TIME	NODES	NODELIST (REASON)
1767	cpu	${\tt mpiblast}$	labinfo	R	9:40:13	1	sdumont1128
1769	cpu	${\tt mpiblast}$	labinfo	R	9:35:10	1	sdumont1130
1770	cpu	${\tt mpiblast}$	labinfo	R	9:33:36	2	sdumont[1000-1001]
1772	cpu	mpiblast	labinfo	R	9:29:48	2	sdumont[1106-1107]
1777	cpu	brams-5.	xrpsouto	R	1:12:10	1	sdumont1126
1776	mesca2	TEST bla	labinfo	R	8:21:18	1	sdumont57



## SLURM: comandos básicos

- sacctmgr: lista acesso às filas
- sinfo: visualiza informação sobre os nós e partições do SLURM
- **squeue:** visualiza informação sobre o status dos jobs e escalonamento
- **srun**: alocação de recursos e distribuição de tarefas
- scontrol: ferramenta para visualizar e/ou modificar o estado de um job
- salloc: obtém uma alocação para o job
- sbatch: submete um script para alocação em uma partição do SLURM
- scancel: cancela um job
- sacct: mostra informação de jobs já submetidos
- sreport: mostra os recursos consumidos



#### srun



#### srun

```
$ srun -p cpu dev
                   -N1
                             -n6
                                             sleep 60 (forma compacta)
                                      -c1
$ squeue -u $USER
     JOBID PARTITION NAME
                              USER
                                      ST
                                              TIME
                                                    NODES NODELIST (REASON)
  10756971 cpu dev
                     sleep rpsouto R
                                              0:40
                                                        3 sdumont1189
$ scontrol --details show job 10756932
  NumNodes=1 NumCPUs=6 NumTasks=6 CPUs/Task=1 ReqB:S:C:T=0:0:*:*
  Nodes=sdumont1189 CPU IDs=0-5 Mem=64000
```



#### srun

```
$ scontrol --details show job 10756971
JobId=10756971 JobName=sleep
  UserId=rpsouto(60879) GroupId=cenapadrjsd(61071) MCS label=N/A
  Priority=5116 Nice=0 Account=Incc QOS=normal
   JobState=RUNNING Reason=None Dependency=(null)
  Requeue=1 Restarts=0 BatchFlag=0 Reboot=0 ExitCode=0:0
  DerivedExitCode=0:0
  RunTime=00:00:26 TimeLimit=00:20:00 TimeMin=N/A
   SubmitTime=2023-01-16T02:23:26 EliqibleTime=2023-01-16T02:23:26
  AccrueTime=2023-01-16T02:23:26
  StartTime=2023-01-16T02:23:33 EndTime=2023-01-16T02:43:33 Deadline=N/A
   SuspendTime=None SecsPreSuspend=0 LastSchedEval=2023-01-16T02:23:33
   Partition=cpu dev AllocNode:Sid=sdumont11:6575
   ReqNodeList=(null) ExcNodeList=(null)
  NodeList=sdumont1189
  BatchHost=sdumont1189
  NumNodes=1 NumCPUs=6 NumTasks=6 CPUs/Task=1 RegB:S:C:T=0:0:*:*
  TRES=cpu=6, mem=62.50G, node=1, billing=6
   Socks/Node=* NtasksPerN:B:S:C=0:0:*:* CoreSpec=*
   JOB GRES=(null)
  Nodes=sdumont1189 CPU IDs=0-5 Mem=64000 GRES=
  MinCPUsNode=1 MinMemoryNode=62.50G MinTmpDiskNode=0
  Features=(null) DelayBoot=00:00:00
  OverSubscribe=OK Contiquous=0 Licenses=(null) Network=(null)
  Command=sleep
  WorkDir=/prj/cenapadrjsd/rpsouto
   Power=
   NtasksPerTRES: 0
```



# Mapeamento (mapping) e vinculação (binding)

#### Mapping define como as tarefas são distribuídas:

- no nível de núcleos
- no nível de sockets
- no nível de nós

#### Binding define a afinidade das tarefas:

- por núcleo
- por socket
- por nó (sem binding)



#### **SDBASE**



5: Cpus allowed list:

```
$ srun -p cpu dev -N1 -n6 -c1 --cpu bind=cores, verbose --label cat /proc/self/status | grep
Cpus allowed list | grep Cpus allowed list
2: cpu-bind=MASK - sdumont1227, task 2 2 [2318]: mask 0x4 set
1: cpu-bind=MASK - sdumont1227, task 1 1 [2317]: mask 0x2 set
3: cpu-bind=MASK - sdumont1227, task 3 3 [2319]: mask 0x8 set
4: cpu-bind=MASK - sdumont1227, task 4 4 [2320]: mask 0x10 set
0: cpu-bind=MASK - sdumont1227, task 0 0 [2316]: mask 0x1 set
5: cpu-bind=MASK - sdumont1227, task 5 5 [2321]: mask 0x20 set
0: Cpus allowed list:
1: Cpus allowed list:
2: Cpus allowed list:
3: Cpus allowed list:
4: Cpus allowed list:
```



```
$ srun -p cpu dev -N2 -n6 -c1 --cpu bind=cores, verbose --label cat /proc/self/status | grep
Cpus allowed list | grep Cpus allowed list
0: cpu-bind=MASK - sdumont1227, task 0 0 [21551]: mask 0x1 set
1: cpu-bind=MASK - sdumont1227, task 1 1 [21552]: mask 0x2 set
2: cpu-bind=MASK - sdumont1227, task 2 2 [21553]: mask 0x4 set
3: cpu-bind=MASK - sdumont1228, task 3 0 [25463]: mask 0x1 set
4: cpu-bind=MASK - sdumont1228, task 4 1 [25464]: mask 0x2 set
5: cpu-bind=MASK - sdumont1228, task 5 2 [25465]: mask 0x4 set
0: Cpus allowed list:
1: Cpus allowed list:
2: Cpus allowed list:
3: Cpus allowed list:
4: Cpus allowed list:
5: Cpus allowed list:
```



```
$ srun -p cpu dev -N2 -n6 -c2 --cpu bind=cores, verbose --label cat /proc/self/status | grep
Cpus allowed list | grep Cpus allowed list
0: cpu-bind=MASK - sdumont1227, task 0 0 [21551]: mask 0x1 set
1: cpu-bind=MASK - sdumont1227, task 1 1 [21552]: mask 0x2 set
2: cpu-bind=MASK - sdumont1227, task 2 2 [21553]: mask 0x4 set
3: cpu-bind=MASK - sdumont1228, task 3 0 [25463]: mask 0x1 set
4: cpu-bind=MASK - sdumont1228, task 4 1 [25464]: mask 0x2 set
5: cpu-bind=MASK - sdumont1228, task 5 2 [25465]: mask 0x4 set
0: Cpus allowed list:
                        0-1
1: Cpus allowed list:
                        2-3
2: Cpus allowed list:
                       4-5
4: Cpus allowed list:
                        2-3
3: Cpus allowed list:
                       0-1
5: Cpus allowed list:
                        4-5
```



8-11

5: Cpus allowed list:

```
$ srun -p cpu dev -N2 -n6 -c4 --cpu bind=cores, verbose --label cat /proc/self/status | grep
Cpus allowed list | grep Cpus allowed list
0: cpu-bind=MASK - sdumont1227, task 0 0 [21551]: mask 0x1 set
1: cpu-bind=MASK - sdumont1227, task 1 1 [21552]: mask 0x2 set
2: cpu-bind=MASK - sdumont1227, task 2 2 [21553]: mask 0x4 set
3: cpu-bind=MASK - sdumont1228, task 3 0 [25463]: mask 0x1 set
4: cpu-bind=MASK - sdumont1228, task 4 1 [25464]: mask 0x2 set
5: cpu-bind=MASK - sdumont1228, task 5 2 [25465]: mask 0x4 set
0: Cpus allowed list:
                        0 - 3
1: Cpus allowed list:
                        4-7
2: Cpus allowed list:
                        8-11
3: Cpus allowed list:
                       0-3
4: Cpus allowed list:
                       4-7
```



8-15

4: Cpus allowed list:

```
$ srun -p cpu dev -N2 -n6 -c8 --cpu bind=cores, verbose --label cat /proc/self/status | grep
Cpus allowed list | grep Cpus allowed list
0: cpu-bind=MASK - sdumont1227, task 0 0 [21551]: mask 0x1 set
1: cpu-bind=MASK - sdumont1227, task 1 1 [21552]: mask 0x2 set
2: cpu-bind=MASK - sdumont1227, task 2 2 [21553]: mask 0x4 set
3: cpu-bind=MASK - sdumont1228, task 3 0 [25463]: mask 0x1 set
4: cpu-bind=MASK - sdumont1228, task 4 1 [25464]: mask 0x2 set
5: cpu-bind=MASK - sdumont1228, task 5 2 [25465]: mask 0x4 set
0: Cpus allowed list:
                        0 - 7
1: Cpus allowed list:
                        8-15
2: Cpus allowed list:
                       16-23
3: Cpus allowed list:
                        0-7
5: Cpus allowed list:
                        16-23
```



```
$ srun -p cpu dev -N2 -n6 -c8 --cpu bind=cores, verbose --label cat /proc/self/status | grep
Cpus allowed list | grep Cpus allowed list
0: cpu-bind=MASK - sdumont1227, task 0 0 [21551]: mask 0x1 set
1: cpu-bind=MASK - sdumont1227, task 1 1 [21552]: mask 0x2 set
2: cpu-bind=MASK - sdumont1227, task 2 2 [21553]: mask 0x4 set
3: cpu-bind=MASK - sdumont1228, task 3 0 [25463]: mask 0x1 set
4: cpu-bind=MASK - sdumont1228, task 4 1 [25464]: mask 0x2 set
5: cpu-bind=MASK - sdumont1228, task 5 2 [25465]: mask 0x4 set
0: Cpus allowed list:
                        0 - 7
1: Cpus allowed list:
                        8-15
                              -> núcleos em diferentes sockets
2: Cpus allowed list:
                        16-23
3: Cpus allowed list:
                        0-7
5: Cpus allowed list:
                       16-23
4: Cpus allowed list:
                              -> núcleos em diferentes sockets
```



```
$ srun -p cpu dev -N2 -n8 -c6 --cpu bind=cores, verbose --label cat /proc/self/status | grep
Cpus allowed list | grep Cpus allowed list
0: cpu-bind=MASK - sdumont1227, task 0 0 [25051]: mask 0x3f set
1: cpu-bind=MASK - sdumont1227, task 1 1 [25052]: mask 0xfc0 set
2: cpu-bind=MASK - sdumont1227, task 2 2 [25053]: mask 0x3f000 set
3: cpu-bind=MASK - sdumont1227, task 3 3 [25054]: mask 0xfc0000 set
4: cpu-bind=MASK - sdumont1228, task 4 0 [28964]: mask 0x3f set
5: cpu-bind=MASK - sdumont1228, task 5 1 [28965]: mask 0xfc0 set
6: cpu-bind=MASK - sdumont1228, task 6 2 [28966]: mask 0x3f000 set
7: cpu-bind=MASK - sdumont1228, task 7 3 [28967]: mask 0xfc0000 set
0: Cpus allowed list:
                        0-5
1: Cpus allowed list:
                     6-11
2: Cpus allowed list: 12-17
3: Cpus allowed list: 18-23
4: Cpus allowed list:
                     0-5
5: Cpus allowed list:
                      6-11
6: Cpus allowed list:
                       12-17
7: Cpus allowed list:
                        18-23
```

Tarefas com núcleos nos mesmos sockets.

```
$ srun -p cpu dev -N2 -n8 -c6 --cpu bind=cores, verbose --label cat /proc/self/status | grep
Cpus allowed list | grep Cpus allowed list
0: cpu-bind=MASK - sdumont1227, task 0 0 [25051]: mask 0x3f set
1: cpu-bind=MASK - sdumont1227, task 1 1 [25052]: mask 0xfc0 set
2: cpu-bind=MASK - sdumont1227, task 2 2 [25053]: mask 0x3f000 set
3: cpu-bind=MASK - sdumont1227, task 3 3 [25054]: mask 0xfc0000 set
4: cpu-bind=MASK - sdumont1228, task 4 0 [28964]: mask 0x3f set
5: cpu-bind=MASK - sdumont1228, task 5 1 [28965]: mask 0xfc0 set
6: cpu-bind=MASK - sdumont1228, task 6 2 [28966]: mask 0x3f000 set
7: cpu-bind=MASK - sdumont1228, task 7 3 [28967]: mask 0xfc0000 set
0: Cpus allowed list:
                        0-5
1: Cpus allowed list: 6-11
2: Cpus allowed list: 12-17
3: Cpus allowed list: 18-23
4: Cpus allowed list:
                     0-5
5: Cpus allowed list:
                     6-11
6: Cpus allowed list:
                     12-17
7: Cpus allowed list:
                        18-23
```

Laboratório Nacional de Computação

```
$ cd $SCRATCH -> vai para o diretório de sua conta na partição do lustre (/scratch)
TODA SUBMISSÃO DE JOB DEVE SER FEITA COM EXECUTÁVEIS INSTALADOS NA PARTIÇÃO /scratch
$ pwd $SCRATCH -> verifica o caminho deste diretório
$ module load git/2.23
$ git clone https://github.com/robertopsouto/ESD2024.git
```





```
ESD2024/
   README.md
    sdbase

    env openmpi

      - NPB3.4.2-MZ
            NPB3.4-MZ-MPI
              — bin
                 ☐ BULL srun openmpi.sh
                BT-MZ
                config
                    make.def
                    suite.def
                Makefile
            README
    sequana
      env openmpi
       NPB3.4.2-MZ
```

```
$ cd ESD2024/sdbase/
$ ls -A1
env_openmpi
NPB3.4.2-MZ

$ cat env_openmpi
module load openmpi/gnu/4.1.2+cuda-11.2
$ source env_openmpi
```



```
$ cd NPB3.4.2-MZ/NPB3.4-MZ-MPI/config/
$ ls -A1
   make.def
  make.def.template
  NAS.samples/
  suite.def
  suite.def
  suite.def.template
$ cat make.def
```



```
$ cat suite.def
# config/suite.def
# This file is used to build several benchmarks with a single command.
# Typing "make suite" in the main directory will build all the benchmarks
# specified in this file.
# Each line of this file contains a benchmark name, and class.
# The name is one of "sp-mz", "bt-mz", and "lu-mz".
# The class is one of "S", "W", and "A" through "F".
# No blank lines.
# The following example builds sample sizes of all benchmarks.
bt-mz
          W
bt-mz
          Α
bt-mz
bt-mz
```



```
$ cd ../
$ pwd
    ../ESD2024/sdbase/NPB3.4.2-MZ/NPB3.4-MZ-MPI
$ make suite --> compila o benchmark BT-MZ
$ cd bin
$ ls -A1
bt-mz.A.x
bt-mz.B.x
bt-mz.C.x
bt-mz.W.x
BULL srun openmpi.sh
```



#### SLURM: comandos básicos

- sacctmgr: lista acesso às filas
- sinfo: visualiza informação sobre os nós e partições do SLURM
- squeue: visualiza informação sobre o status dos jobs e escalonamento
- srun: alocação de recursos e distribuição de tarefas
- scontrol: ferramenta para visualizar e/ou modificar o estado de um job
- salloc: obtém uma alocação para o job
- **sbatch**: submete um script para alocação em uma partição do SLURM
- scancel: cancela um job
- sacct: mostra informação de jobs já submetidos
- sreport: mostra os recursos consumidos



```
$ srun -p cpu dev -N1 -n1 ./bt-mz.W.x --> submete o job com srun
-N1 (--nodes=1): define o número de nós a serem alocados
-n1 (--ntasks=1): define o número total de tarefas (MPI ranks) a serem executadas
$ salloc -p cpu dev -N1 -n1 mpirun ./bt-mz.W.x --> submete o job com salloc
salloc: Granted job allocation 105518
Class
 Size
                               64x
                                     64x 8
                                        200
 Iterations
                                       5.82
 Time in seconds =
 Total processes =
 Total threads
Mop/s total
                                    2464.61
Mop/s/thread
                                    2464.61
                 =
salloc: Relinquishing job allocation 105518
salloc: Job allocation 105518 has been revoked.
```



```
$ srun -p sequana cpu dev -N1 -n1 ./bt-mz.W.x --> submete o job com srun
-N1 (--nodes=1): define o número de nós a serem alocados
-n1 (--ntasks=1): define o número total de tarefas (MPI ranks) a serem executadas
$ salloc -p sequana cpu dev -N1 -n1 mpirun ./bt-mz.W.x --> submete o job com salloc
salloc: Granted job allocation 105518
Class
Size
                               64x
                                     64x 8
                                        200
Iterations
                                       5.82
Time in seconds =
Total processes =
Total threads
Mop/s total
                                    2464.61
Mop/s/thread
                                    2464.61
                 =
salloc: Relinquishing job allocation 105518
salloc: Job allocation 105518 has been revoked.
```



```
$ salloc -p cpu dev -N1 -n2 mpirun -n 1 ./bt-mz.W.x --> submete o job com salloc
salloc: Granted job allocation 105519
Class
                                          W
Size
                                     64x 8
                               64x
 Iterations
                                        200
 Time in seconds =
                                       2.96
 Total processes =
 Total threads
Mop/s total
                                    4851.15
Mop/s/thread
                                    2425.57
```

salloc: Relinquishing job allocation 105519

salloc: Job allocation 105519 has been revoked.



```
$ srun -p cpu_dev -N1 -n2
                               ./bt-mz.W.x
                                               --> submete o job com srun
Class
                                          W
Size
                                      64x 8
                               64x
 Iterations
                                         200
 Time in seconds =
                                        2.96
 Total processes =
Total threads
Mop/s total
                                     4851.15
Mop/s/thread
                                     2425.57
```



```
$ srun -p cpu dev -N1 -n1 -c2 ./bt-mz.W.x --> para execução multi-thread
-N1 (--nodes=1): define o número de nós a serem alocados
-n1 (--ntasks=1): define o número total de tarefas (MPI ranks) a serem executadas
-c2 (--cpus-per-task=2): define o número de cpus por tarefa (MPI rank)
BT-MZ Benchmark Completed.
Class
                                     64x 8
 Size
                               64x
 Iterations
                                        200
 Time in seconds =
                                       5.85
                                             --> desempenho aquém do esperado
 Total processes =
                                           1
 Total threads
```

```
$ srun -p cpu dev -N1 -n1 -c2 ./bt-mz.W.x --> para execução multi-thread
-N1 (--nodes=1): define o número de nós a serem alocados
-n1 (--ntasks=1): define o número total de tarefas (MPI ranks) a serem executadas
-c2 (--cpus-per-task=2): define o número de cpus por tarefa (MPI rank)
BT-MZ Benchmark Completed.
Class
                                     64x 8
 Size
                               64x
 Iterations
                                        200
 Time in seconds =
                                       5.85 --> definir var. de amb. OMP NUM THREADS
 Total processes =
                                          1
 Total threads
$ export OMP NUM THREADS=2 --> (iqual a --cpus-per-task)
```



```
$ srun -p cpu dev -N1 -n1 -c2 ./bt-mz.W.x --> para execução multi-thread
-N1 (--nodes=1): define o número de nós a serem alocados
-n1 (--ntasks=1): define o número total de tarefas (MPI ranks) a serem executadas
-c2 (--cpus-per-task=2): define o número de cpus por tarefa (MPI rank)
BT-MZ Benchmark Completed.
Class
                                     64x 8
 Size
                               64x
 Iterations
                                        200
                                       3.03 --> redução de tempo
 Time in seconds =
 Total processes =
 Total threads
```



#### SLURM: comandos básicos

- sacctmgr: lista acesso às filas
- sinfo: visualiza informação sobre os nós e partições do SLURM
- **squeue:** visualiza informação sobre o status dos jobs e escalonamento
- **srun**: alocação de recursos e distribuição de tarefas
- scontrol: ferramenta para visualizar e/ou modificar o estado de um job
- salloc: obtém uma alocação para o job
- sbatch: submete um script para alocação em uma partição do SLURM
- scancel: cancela um job
- sacct: mostra informação de jobs já submetidos
- sreport: mostra os recursos consumidos



#### SLURM: comandos básicos

#### sbatch

- parâmetros na linha de comando
- parâmetros no script

principais opções de configuração:

- --time (-t)
- --nodes (-N)
- --ntasks (-n)
- --ntasks-per-node
- --cpus-per-task (-c)
- --partition (-p)



BULL\_srun\_openmpi.sh

```
#!/bin/bash
#SBATCH --nodes=1
                                        # here the number of nodes
#SBATCH --ntasks=1
                                        # here total number of mpi tasks
#SBATCH --cpus-per-task=1
                                        # number of cores per node
#SBATCH -p cpu dev
                                        # target partition
#SBATCH -J NPB BT-MZ
                                        # job name
#SBATCH --time=00:05:00
                                        # time limit
                                        # to have exclusive use of your nodes
#SBATCH --exclusive
echo "Cluster configuration:"
echo "==="
echo "Partition: " $SLURM JOB PARTITION
echo "Number of nodes: " $SLURM NNODES
echo "Number of MPI processes: " $SLURM NTASKS " (" $SLURM NNODES " nodes)"
echo "Number of MPI processes per node: " $SLURM NTASKS PER NODE
echo "Number of threads per MPI process: " $SLURM CPUS PER TASK
echo "NPB Benchmark: " $1
echo "Bechmark class problem: " $2
```



BULL\_srun\_openmpi.sh (cont.)

```
COMPILER
module load openmpi/gnu/4.1.2+cuda-11.2
DIR=$PWD
bench=${1}
class=${2}
execfile="${bench}.${class}.x"
BIN=$DIR/${execfile}
export OMPI MCA opal warn on missing libcuda=0
export OMP NUM THREADS=$SLURM CPUS PER TASK
cd $DIR
srun -n $SLURM NTASKS $BIN
dirdest="${bench} ${class} MPI-${SLURM NTASKS} OMP-${SLURM CPUS PER TASK} JOBID-${SLURM JOBID}"
mkdir $dirdest
cp slurm-${SLURM JOBID}.out $dirdest/
```



#### Variáveis de ambiente do SLURM

#### Alguns exemplos:

```
SLURM_JOB_PARTITION
SLURM_NNODES
SLURM_NTASKS
SLURM_NTASKS_PER_NODE
SLURM_CPUS_PER_TASK
SLURM_JOBID
SLURM_JOB_NODELIST
SLURM_SUBMIT_DIR
```



```
$ sbatch BULL srun openmpi.sh bt-mz W
Submitted batch job 105539
$ squeue -u $USER
            JOBID PARTITION
                                NAME
                                         USER ST
                                                       TIME
                                                             NODES NODELIST (REASON)
            105539 sequana c NPB BT-M professo R
                                                       0:05
                                                                 1 sdumont5000
$ ls bt-mz W MPI-1 OMP-1 JOBID-105539/
slurm-105539.out --> arquivo gerado pelo SLURM com a saída da aplicação
$ sbatch -N2 -n2 -c1 ./BULL srun openmpi.sh bt-mz W
Os parâmetros por linha de comando têm precedência sobre os definidos no script
$ ls bt-mz W MPI-2 OMP-1 JOBID-105540
slurm-105540.out
```



#### scontrol: alterando parâmetro do job

```
--dependency (-d): adia o início do job até que a dependência especificada seja satisfeita
```

```
$ sbatch BULL srun openmpi.sh bt-mz A
Submitted batch job 105558
$ sbatch -d afterany:105558 BULL srun openmpi.sh bt-mz A
Submitted batch job 105559
$ sbatch -d afterany:105559 BULL srun openmpi.sh bt-mz A
Submitted batch job 105560
$ sbatch -d afterany:105560 BULL srun openmpi.sh bt-mz A
Submitted batch job 105561
$ squeue -u $USER
             JOBID PARTITION
                                          USER ST
                                 NAME
                                                         TIME
                                                               NODES NODELIST (REASON)
            105559 treinamen NPB BT-M professo PD
                                                         0:00
                                                                   1 (Dependency)
```

105560 treinamen NPB BT-M professo PD

105561 treinamen NPB BT-M professo PD

105558 treinamen NPB BT-M professo R



0:00

0:00

0:26

1 (Dependency)
1 (Dependency)

1 sdumont5000

#### scontrol: alterando parâmetro do job

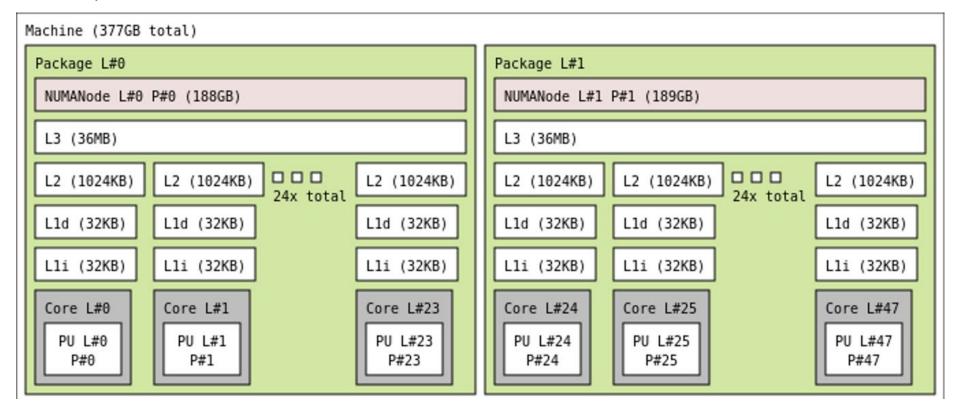
```
$ scontrol show jobid 105561
JobId=105561 JobName=NPB BT-MZ
  UserId=professor(63001) GroupId=treinamento(61052)
   Priority=1791 Nice=0 Account=treinamento QOS=normal
   JobState=PENDING Reason=Dependency Dependency=afterany:105560
   Requeue=1 Restarts=0 BatchFlag=1 Reboot=0 ExitCode=0:0
  RunTime=00:00:00 TimeLimit=00:05:00 TimeMin=N/A
   SubmitTime=2017-07-30T17:42:04 EliqibleTime=Unknown
   StartTime=Unknown EndTime=Unknown
   PreemptTime=None SuspendTime=None SecsPreSuspend=0
   Partition=cpu AllocNode:Sid=sdumont14:19952
  ReqNodeList=(null) ExcNodeList=(null)
  NodeList=(null)
  NumNodes=1-1 NumCPUs=1 CPUs/Task=1 ReqB:S:C:T=0:0:*:1
   Socks/Node=* NtasksPerN:B:S:C=1:0:*:* CoreSpec=*
  MinCPUsNode=1 MinMemoryNode=0 MinTmpDiskNode=0
  Features=(null) Gres=(null) Reservation=(null)
   Shared=0 Contiquous=0 Licenses=(null) Network=(null)
```



```
$ scontrol update JobId=105561 Partition=cpu dev
$ scontrol show jobid 105561
JobId=105561 JobName=NPB BT-MZ
  UserId=professor(63001) GroupId=treinamento(61052)
  Priority=1791 Nice=0 Account=treinamento QOS=normal
  JobState=PENDING Reason=Dependency Dependency=afterany:105560
  Requeue=1 Restarts=0 BatchFlag=1 Reboot=0 ExitCode=0:0
  RunTime=00:00:00 TimeLimit=00:05:00 TimeMin=N/A
  SubmitTime=2017-07-30T17:42:04 EliqibleTime=Unknown
  StartTime=Unknown EndTime=Unknown
  PreemptTime=None SuspendTime=None SecsPreSuspend=0
  Partition=cpu dev AllocNode:Sid=sdumont14:19952
  ReqNodeList=(null) ExcNodeList=(null)
  NodeList=(null)
  NumNodes=1-1 NumCPUs=1 CPUs/Task=1 ReqB:S:C:T=0:0:*:1
  Socks/Node=* NtasksPerN:B:S:C=1:0:*:* CoreSpec=*
  MinCPUsNode=1 MinMemoryNode=0 MinTmpDiskNode=0
  Features=(null) Gres=(null) Reservation=(null)
  Shared=0 Contiquous=0 Licenses=(null) Network=(null)
```



#### SEQUANA





```
ESD2024/
   README.md
   sdbase
    — env openmpi
   sequana
     env openmpi
     — NPB3.4.2-MZ
          NPB3.4-MZ-MPI
             - bin
               ☐ BULL srun openmpi.sh
              BT-MZ
              config
                 make.def
                  suite.def
              Makefile
           README
```

```
$ cd $SCRATCH -> vai para o diretório de sua conta na partição do lustre (/scratch)
TODA SUBMISSÃO DE JOB DEVE SER FEITA COM EXECUTÁVEIS INSTALADOS NA PARTIÇÃO /scratch
$ pwd $SCRATCH -> verifica o caminho deste diretório

$ ssh sdumont18
$ module load sequana/current
Loading SEQUANA Software environment
$ module load git/2.23_sequana
```

```
$ cd ESD2024/sequana/
$ ls -A1
env_openmpi
NPB3.4.2-MZ

$ cat env_openmpi
module load openmpi/gnu/4.1.2+cuda-11.2_sequana
$ source env openmpi
```



```
$ cd NPB3.4.2-MZ/NPB3.4-MZ-MPI/config/
$ ls -A1
   make.def
  make.def.template
  NAS.samples/
  suite.def
  suite.def
  suite.def.template
$ cat make.def
```



```
$ cat suite.def
# config/suite.def
# This file is used to build several benchmarks with a single command.
# Typing "make suite" in the main directory will build all the benchmarks
# specified in this file.
# Each line of this file contains a benchmark name, and class.
# The name is one of "sp-mz", "bt-mz", and "lu-mz".
# The class is one of "S", "W", and "A" through "F".
# No blank lines.
# The following example builds sample sizes of all benchmarks.
bt-mz
          W
bt-mz
          Α
bt-mz
bt-mz
```



```
$ cd ../
$ pwd
    ../ESD2024/sequana/NPB3.4.2-MZ/NPB3.4-MZ-MPI
$ make suite --> compila o benchmark BT-MZ
$ cd bin
$ ls -A1
bt-mz.A.x
bt-mz.B.x
bt-mz.C.x
bt-mz.W.x
BULL srun openmpi.sh
```



## SLURM: comandos básicos

- sacctmgr: lista acesso às filas
- sinfo: visualiza informação sobre os nós e partições do SLURM
- squeue: visualiza informação sobre o status dos jobs e escalonamento
- srun: alocação de recursos e distribuição de tarefas
- scontrol: ferramenta para visualizar e/ou modificar o estado de um job
- salloc: obtém uma alocação para o job
- **sbatch**: submete um script para alocação em uma partição do SLURM
- scancel: cancela um job
- sacct: mostra informação de jobs já submetidos
- sreport: mostra os recursos consumidos



```
$ srun -p sequana cpu dev -N1 -n1 ./bt-mz.W.x --> submete o job com srun
-N1 (--nodes=1): define o número de nós a serem alocados
-n1 (--ntasks=1): define o número total de tarefas (MPI ranks) a serem executadas
$ salloc -p sequana cpu dev -N1 -n1 mpirun ./bt-mz.W.x --> submete o job com salloc
salloc: Granted job allocation 105518
Class
Size
                               64x
                                     64x 8
                                        200
Iterations
                                       5.82
Time in seconds =
Total processes =
Total threads
Mop/s total
                                    2464.61
Mop/s/thread
                                    2464.61
                 =
salloc: Relinquishing job allocation 105518
salloc: Job allocation 105518 has been revoked.
```



```
$ salloc -p sequana_cpu_dev -N1 -n2 mpirun -n 1 ./bt-mz.W.x --> submete o job com salloc
salloc: Granted job allocation 105519
Class
                                         W
Size
                                     64x 8
                               64x
 Iterations
                                        200
 Time in seconds =
                                       2.96
 Total processes =
 Total threads
Mop/s total
                                    4851.15
Mop/s/thread
                                    2425.57
```

salloc: Relinquishing job allocation 105519

salloc: Job allocation 105519 has been revoked.



```
$ srun -p sequana cpu dev -N1 -n2
                                       ./bt-mz.W.x
                                                       --> submete o job com srun
Class
                                          W
Size
                                      64x 8
                                64x
 Iterations
                                         200
 Time in seconds =
                                        2.96
 Total processes =
Total threads
Mop/s total
                                     4851.15
Mop/s/thread
                                     2425.57
```



```
$ srun -p sequana cpu dev -N1 -n1 -c2 ./bt-mz.W.x --> para execução multi-thread
-N1 (--nodes=1): define o número de nós a serem alocados
-n1 (--ntasks=1): define o número total de tarefas (MPI ranks) a serem executadas
-c2 (--cpus-per-task=2): define o número de cpus por tarefa (MPI rank)
BT-MZ Benchmark Completed.
Class
                                     64x 8
 Size
                               64x
 Iterations
                                        200
 Time in seconds =
                                       5.85
                                             --> desempenho aquém do esperado
 Total processes =
                                           1
 Total threads
```



```
$ srun -p sequana cpu dev -N1 -n1 -c2 ./bt-mz.W.x --> para execução multi-thread
-N1 (--nodes=1): define o número de nós a serem alocados
-n1 (--ntasks=1): define o número total de tarefas (MPI ranks) a serem executadas
-c2 (--cpus-per-task=2): define o número de cpus por tarefa (MPI rank)
BT-MZ Benchmark Completed.
Class
                                     64x 8
 Size
                               64x
 Iterations
                                        200
 Time in seconds =
                                       5.85 --> definir var. de amb. OMP NUM THREADS
 Total processes =
                                          1
 Total threads
$ export OMP NUM THREADS=2 --> (iqual a --cpus-per-task)
```



```
$ srun -p sequana cpu dev -N1 -n1 -c2 ./bt-mz.W.x --> para execução multi-thread
-N1 (--nodes=1): define o número de nós a serem alocados
-n1 (--ntasks=1): define o número total de tarefas (MPI ranks) a serem executadas
-c2 (--cpus-per-task=2): define o número de cpus por tarefa (MPI rank)
BT-MZ Benchmark Completed.
Class
                                     64x 8
 Size
                               64x
 Iterations
                                        200
                                       3.03 --> redução de tempo
 Time in seconds =
 Total processes =
 Total threads
```



## SLURM: comandos básicos

- sacctmgr: lista acesso às filas
- sinfo: visualiza informação sobre os nós e partições do SLURM
- **squeue:** visualiza informação sobre o status dos jobs e escalonamento
- **srun**: alocação de recursos e distribuição de tarefas
- scontrol: ferramenta para visualizar e/ou modificar o estado de um job
- salloc: obtém uma alocação para o job
- sbatch: submete um script para alocação em uma partição do SLURM
- scancel: cancela um job
- sacct: mostra informação de jobs já submetidos
- sreport: mostra os recursos consumidos



## SLURM: comandos básicos

#### sbatch

- parâmetros na linha de comando
- parâmetros no script

principais opções de configuração:

- --time (-t)
- --nodes (-N)
- --ntasks (-n)
- --ntasks-per-node
- --cpus-per-task (-c)
- --partition (-p)



BULL\_srun\_openmpi.sh

```
#!/bin/bash
#SBATCH --nodes=1
                                        # here the number of nodes
#SBATCH --ntasks=1
                                        # here total number of mpi tasks
#SBATCH --cpus-per-task=1
                                        # number of cores per node
#SBATCH -p sequana cpu dev
                                                # target partition
#SBATCH -J NPB BT-MZ
                                        # job name
#SBATCH --time=00:05:00
                                        # time limit
                                        # to have exclusive use of your nodes
#SBATCH --exclusive
echo "Cluster configuration:"
echo "==="
echo "Partition: " $SLURM JOB PARTITION
echo "Number of nodes: " $SLURM NNODES
echo "Number of MPI processes: " $SLURM NTASKS " (" $SLURM NNODES " nodes)"
echo "Number of MPI processes per node: " $SLURM NTASKS PER NODE
echo "Number of threads per MPI process: " $SLURM CPUS PER TASK
echo "NPB Benchmark: " $1
echo "Bechmark class problem: " $2
```



BULL\_srun\_openmpi.sh (cont.)

```
COMPILER
module load sequana/current
module load openmpi/gnu/4.1.2+cuda-11.2 sequana
DIR=$PWD
bench=${1}
class=${2}
execfile="${bench}.${class}.x"
BIN=$DIR/${execfile}
export OMPI MCA opal warn on missing libcuda=0
export OMP NUM THREADS=$SLURM CPUS PER TASK
cd $DIR
srun -n $SLURM NTASKS $BIN
dirdest="${bench} ${class} MPI-${SLURM NTASKS} OMP-${SLURM CPUS PER TASK} JOBID-${SLURM JOBID}"
mkdir $dirdest
cp slurm-${SLURM JOBID}.out $dirdest/
```



## Variáveis de ambiente do SLURM

## Alguns exemplos:

```
SLURM_JOB_PARTITION
SLURM_NNODES
SLURM_NTASKS
SLURM_NTASKS_PER_NODE
SLURM_CPUS_PER_TASK
SLURM_JOBID
SLURM_JOB_NODELIST
SLURM_SUBMIT_DIR
```



```
$ sbatch BULL srun openmpi.sh bt-mz W
Submitted batch job 105539
$ squeue -u $USER
            JOBID PARTITION
                                NAME
                                         USER ST
                                                       TIME
                                                             NODES NODELIST (REASON)
            105539 sequana c NPB BT-M professo R
                                                       0:05
                                                                 1 sdumont5000
$ ls bt-mz W MPI-1 OMP-1 JOBID-105539/
slurm-105539.out --> arquivo gerado pelo SLURM com a saída da aplicação
$ sbatch -N2 -n2 -c1 ./BULL srun openmpi.sh bt-mz W
Os parâmetros por linha de comando têm precedência sobre os definidos no script
$ ls bt-mz W MPI-2 OMP-1 JOBID-105540
slurm-105540.out
```



```
$ sbatch BULL_srun_openmpi.sh bt-mz A
Submitted batch job 105558
$ sbatch -d afterany:105558 BULL_srun_openmpi.sh bt-mz A
Submitted batch job 105559
$ sbatch -d afterany:105559 BULL srun openmpi.sh bt-mz A
```

--dependency (-d): adia o início do job até que a dependência especificada seja satisfeita

\$ sbatch -d afterany:105560 BULL srun openmpi.sh bt-mz A

Submitted batch job 105561

Submitted batch job 105560

\$ squeue -u \$USER

JOBID	PARTITION	NAME	USER	ST	TIME	NODES	NODELIST (REASON)
105559	treinamen	NPB_BT-M	professo	PD	0:00	1	(Dependency)
105560	treinamen	NPB_BT-M	professo	PD	0:00	1	(Dependency)
105561	treinamen	NPB_BT-M	professo	PD	0:00	1	(Dependency)
105558	treinamen	NPB BT-M	professo	R	0:26	1	sdumont5000



```
$ scontrol show jobid 105561
JobId=105561 JobName=NPB BT-MZ
  UserId=professor(63001) GroupId=treinamento(61052)
   Priority=1791 Nice=0 Account=treinamento QOS=normal
   JobState=PENDING Reason=Dependency Dependency=afterany:105560
   Requeue=1 Restarts=0 BatchFlag=1 Reboot=0 ExitCode=0:0
  RunTime=00:00:00 TimeLimit=00:05:00 TimeMin=N/A
   SubmitTime=2017-07-30T17:42:04 EliqibleTime=Unknown
   StartTime=Unknown EndTime=Unknown
   PreemptTime=None SuspendTime=None SecsPreSuspend=0
   Partition=sequana cpu dev AllocNode:Sid=sdumont14:19952
  ReqNodeList=(null) ExcNodeList=(null)
  NodeList=(null)
  NumNodes=1-1 NumCPUs=1 CPUs/Task=1 ReqB:S:C:T=0:0:*:1
   Socks/Node=* NtasksPerN:B:S:C=1:0:*:* CoreSpec=*
  MinCPUsNode=1 MinMemoryNode=0 MinTmpDiskNode=0
  Features=(null) Gres=(null) Reservation=(null)
   Shared=0 Contiguous=0 Licenses=(null) Network=(null)
```



```
$ scontrol update JobId=105561 Partition=sequana cpu dev
$ scontrol show jobid 105561
JobId=105561 JobName=NPB BT-MZ
  UserId=professor(63001) GroupId=treinamento(61052)
   Priority=1791 Nice=0 Account=treinamento QOS=normal
   JobState=PENDING Reason=Dependency Dependency=afterany:105560
   Requeue=1 Restarts=0 BatchFlag=1 Reboot=0 ExitCode=0:0
  RunTime=00:00:00 TimeLimit=00:05:00 TimeMin=N/A
   SubmitTime=2017-07-30T17:42:04 EliqibleTime=Unknown
   StartTime=Unknown EndTime=Unknown
   PreemptTime=None SuspendTime=None SecsPreSuspend=0
   Partition=sequana cpu dev AllocNode:Sid=sdumont14:19952
  RegNodeList=(null) ExcNodeList=(null)
  NodeList=(null)
  NumNodes=1-1 NumCPUs=1 CPUs/Task=1 ReqB:S:C:T=0:0:*:1
   Socks/Node=* NtasksPerN:B:S:C=1:0:*:* CoreSpec=*
  MinCPUsNode=1 MinMemoryNode=0 MinTmpDiskNode=0
  Features=(null) Gres=(null) Reservation=(null)
   Shared=0 Contiguous=0 Licenses=(null) Network=(null)
```



## SLURM: comandos básicos

- sacctmgr: lista acesso às filas
- sinfo: visualiza informação sobre os nós e partições do SLURM
- squeue: visualiza informação sobre o status dos jobs e escalonamento
- srun: alocação de recursos e distribuição de tarefas
- scontrol: ferramenta para visualizar e/ou modificar o estado de um job
- salloc: obtém uma alocação para o job
- sbatch: submete um script para alocação em uma partição do SLURM.
- scancel: cancela um job
- sacct: mostra informação de jobs já submetidos
- sreport: mostra os recursos consumidos



<pre>\$ sacct</pre>						
158796	mpirun	treinamen+	treinamen+	1	FAILED	1:0
158798	mpirun	treinamen+	treinamen+	2	COMPLETED	0:0
158798.0	orted		treinamen+	2	COMPLETED	0:0
158802	bt-mz.A.2	treinamen+	treinamen+	2	CANCELLED+	0:0
158803	bt-mz.A.2	treinamen+	treinamen+	2	COMPLETED	0:0
158804	bt-mz.W.2	treinamen+	treinamen+	2	COMPLETED	0:0
158809	mpirun	treinamen+	treinamen+	2	COMPLETED	0:0
158809.0	orted		treinamen+	2	COMPLETED	0:0
158810	bt-mz.W.2	treinamen+	treinamen+	2	COMPLETED	0:0
158811	bt-mz.W.2	treinamen+	treinamen+	2	COMPLETED	0:0



\$ sacct -j 158811											
	JobID	JobName	Partition	Account	AllocCPUS	State	ExitCode				
158811		bt-mz.W.2	treinamen+	treinamen+	2	COMPLETED	0:0				



\$ sacct -e

AllocCPUS AllocGRES Account AssocID

AveCPU AveCPUFreq AveDiskRead AveDiskWrite

AvePages AveRSS AveVMSize BlockID

Cluster Comment ConsumedEnergy ConsumedEnergyRaw

CPUTime CPUTimeRAW DerivedExitCode Elapsed

Eligible End ExitCode GID

Group JobID JobIDRaw JobName

Layout MaxDiskRead MaxDiskReadNode MaxDiskReadTask

MaxDiskWrite MaxDiskWriteNode MaxDiskWriteTask MaxPages

MaxPagesNode MaxPagesTask MaxRSS MaxRSSNode

MaxRSSTask MaxVMSize MaxVMSizeNode MaxVMSizeTask

MinCPU MinCPUNode MinCPUTask NCPUS

NNodes NodeList NTasks Priority

Partition QOS QOSRAW ReqCPUFreq

ReqCPUS ReqGRES ReqMem Reservation

ReservationId Reserved ResvCPU ResvCPURAW

Start State Submit Suspended

SystemCPU Timelimit TotalCPU UID

User UserCPU WCKey WCKeyID

Nacional de Computação Científica

\$ sacc	t -j 158	8811forma	format=JobID, JobName, Elapsed, NodeI				
	JobID	JobName	Elapsed	NodeList			
158811		bt-mz.W.2	00:00:04	sdumont5000			



## SLURM: comandos básicos

- sacctmgr: lista acesso às filas
- sinfo: visualiza informação sobre os nós e partições do SLURM
- squeue: visualiza informação sobre o status dos jobs e escalonamento
- srun: alocação de recursos e distribuição de tarefas
- scontrol: ferramenta para visualizar e/ou modificar o estado de um job
- salloc: obtém uma alocação para o job
- sbatch: submete um script para alocação em uma partição do SLURM
- scancel: cancela um job
- sacct: mostra informação de jobs já submetidos
- **sreport**: mostra os recursos consumidos



## sreport: mostra os recursos consumidos

Exibe a quantidade de horas utilizada pelos Projetos durante um período, delimitado pelos parâmetros start e end.

\$ sreport -t hours cluster **AccountUtilizationByUser** start=AAAA-MM-DD end=AAAA-MM-DD \
Accounts=**PROJETO Tree** 

\$ sreport -t hours cluster AccountUtilizationByUser start=2023-05-01 end=2023-06-01 Accounts=Incc Tree

-----

Cluster/Account/User Utilization 2023-05-01T00:00:00 - 2023-05-31T23:59:59 (2678400 secs) Usage reported in CPU Hours

\_\_\_\_\_\_

Cluster		Account	Login	Proper Name	Used	Energy						
sdumont	lncc				 15643	45565	<	Total	do	Projeto		
sdumont	prjssisd				1521	38303	<	Total	do	Projeto	vinculado	,
sdumont	prjssisd	and	lrercsd A	ndre Ramos Ca+	658	0						
sdumont	prjssisd	bru	noafsd B	runo Alvez Fa+	863	38303						
sdumont	prjstasd				9508	3822	<	Total	do	Projeto	vinculado	,
sdumont	prjstasd	cai	.o.san+ C	aio Graco Per+	118	0						
sdumont	pristasd	cai	o.san+ C	aio Graco Per+	9390	3822						



## sreport: mostra os recursos consumidos

Exibe a quantidade de horas utilizada pelo projeto durante um período, delimitado pelos parâmetros *start* e *end*. Útil para o <u>coordenador</u> do Projeto

\$ sreport -t hours cluster **UserUtilizationByAccount** start=AAAA-MM-DD end=AAAA-MM-DD \ Accounts=**PROJETO** 

\$ sreport -t hours cluster UserUtilizationByAccount start=2023-05-01 end=2023-06-01 Accounts=prjssisd

\_\_\_\_\_\_

 $\label{localization} {\tt Cluster/User/Account~Utilization~2023-05-01T00:00:00~-~2023-05-31T23:59:59~(2678400~secs)} \\ {\tt Usage~reported~in~CPU~Hours}$ 

Cluster	Login	Proper Name	Account	Used	Energy
sdumont	brunoafsd	Bruno Alves Fa+	prjssisd	8509	5
sdumont	andrercsd	Andre Ramos Ca+	prjssisd	8083	0
sdumont	jpassos	Jeferson Passos	prjssisd	7660	0
sdumont	carlos.a+	Carlos Daniel +	prjssisd	5964	51
sdumont	bruno.fa+	Bruno Fagundes+	prjssisd	3404	0
sdumont	fabio.so+	Fabio Moreira +	prjssisd	149	0
sdumont	regio.pi+	Regio Pires	prjssisd	33	121



## Uso das filas com GPU

#### **SDBASE**

nvidia\_dev nvidia\_long nvidia\_scal

#### **SEQUANA**

sequana\_gpu\_dev
sequana\_gpu\_long
sequana\_gpu\_shared



- Carregar o ambiente com o NVIDIA CUDA Toolkit v11.2
   \$ module load cuda/11.2
- Verificar a configuração de GPU do nó
   \$ srun -p nvidia dev nvidia-smi



```
srun: job 10857658 has been allocated resources
Sat Jan 20 13:57:26 2024
| NVIDIA-SMI 470.82.01 | Driver Version: 470.82.01 | CUDA Version: 11.4 |
______
GPU Name Persistence-M| Bus-Id Disp.A | Volatile Uncorr. ECC |
Fan Temp Perf Pwr:Usage/Cap| Memory-Usage | GPU-Util Compute M. |
                                        MIG M. I
0 Tesla K40t On | 00000000:01:00.0 Off |
                                        0 1
N/A 41C P8 21W / 235W | 0MiB / 11441MiB | 0% Default |
                                           N/A |
  1 Tesla K40t On | 00000000:81:00.0 Off |
N/A 41C P8 20W / 235W | 0MiB / 11441MiB | 0% Default |
                                           N/A I
 ------
 ______
Processes:
 GPU GI CI PID
                 Type Process name
                                     GPU Memory |
     ID
        ID
                                       Usage |
  _____
                                                  Laboratório
 No running processes found Escola Santos Dumont - 22 de Janeiro de 2024
```

srun: job 10857658 queued and waiting for resources

- Copiar os exemplos do NVIDIA CUDA Toolkit v11.2
   \$ cd \$SCRATCH
   \$ cuda-install-samples-11.2.sh \$SCRATCH
   Copying samples to /scratch/cenapadrjsd/rpsouto/NVIDIA\_CUDA-11.2\_Samples now...
   Finished copying samples.
- Verificar exemplo de multiplicação de matrizes
   \$ cd \$SCRATCH/NVIDIA\_CUDA-11.2\_Samples/0\_Simple/matrixMul
   \$ 1s
   Makefile matrixMul.cu NsightEclipse.xml readme.txt



Compilar exemplo de multiplicação de matrizes

\$ 1s

```
$ make
/usr/local/cuda-11.2/bin/nvcc -ccbin g++ -I../../common/inc -m64 --threads 0 -gencode
arch=compute 35,code=sm 35 -gencode arch=compute 37,code=sm 37 -gencode arch=compute 50,code=sm 50
-gencode arch=compute 52,code=sm 52 -gencode arch=compute 60,code=sm 60 -gencode
arch=compute 61,code=sm 61 -gencode arch=compute 70,code=sm 70 -gencode arch=compute 75,code=sm 75
-gencode arch=compute 80,code=sm 80 -gencode arch=compute 86,code=sm 86 -gencode
arch=compute 86,code=compute 86 -o matrixMul.o -c matrixMul.cu
nvcc warning: The 'compute 35', 'compute 37', 'compute 50', 'sm 35', 'sm 37' and 'sm 50'
architectures are deprecated, and may be removed in a future release (Use
-Wno-deprecated-qpu-targets to suppress warning).
/usr/local/cuda-11.2/bin/nvcc -ccbin g++ -m64
                                                     -gencode arch=compute 35,code=sm 35 -gencode
arch=compute 37,code=sm 37 -gencode arch=compute 50,code=sm 50 -gencode arch=compute 52,code=sm 52
-gencode arch=compute 60,code=sm 60 -gencode arch=compute 61,code=sm 61 -gencode
arch=compute 70,code=sm 70 -gencode arch=compute 75,code=sm 75 -gencode arch=compute 80,code=sm 80
-gencode arch=compute 86,code=sm 86 -gencode arch=compute 86,code=compute 86 -o matrixMul
matrixMul.o
nvcc warning: The 'compute 35', 'compute 37', 'compute 50', 'sm 35', 'sm 37' and 'sm 50'
architectures are deprecated, and may be removed in a future release (Use
-Wno-deprecated-gpu-targets to suppress warning).
mkdir -p ../../bin/x86 64/linux/release
cp matrixMul ../../bin/x86 64/linux/release
```



Executar exemplo de multiplicação de matrizes

```
$ srun -p nvidia_dev ./matrixMul -wA=1024 -hA=256 -wB=256 -hB=1024
srun: job 10857663 queued and waiting for resources
srun: job 10857663 has been allocated resources
[Matrix Multiply Using CUDA] - Starting...
GPU Device 0: "Kepler" with compute capability 3.5

MatrixA(1024,256), MatrixB(256,1024)
Computing result using CUDA Kernel...
done
Performance= 310.19 GFlop/s, Time= 0.433 msec, Size= 134217728 Ops,
WorkgroupSize= 1024 threads/block
Checking computed result for correctness: Result = PASS
```



Executar exemplo de multiplicação de matrizes

```
$ srun -p nvidia_dev ./matrixMul -wA=2048 -hA=256 -wB=256 -hB=2048 srun: job 10857664 queued and waiting for resources srun: job 10857664 has been allocated resources [Matrix Multiply Using CUDA] - Starting...

GPU Device 0: "Kepler" with compute capability 3.5

MatrixA(2048,256), MatrixB(256,2048)

Computing result using CUDA Kernel...

done

Performance= 311.69 GFlop/s, Time= 0.861 msec, Size= 268435456 Ops, WorkgroupSize= 1024 threads/block

Checking computed result for correctness: Result = PASS
```



Executar exemplo de multiplicação de matrizes

```
$ srun -p nvidia_dev ./matrixMul -wA=4096 -hA=256 -wB=256 -hB=4096
srun: job 10857665 queued and waiting for resources
srun: job 10857665 has been allocated resources
[Matrix Multiply Using CUDA] - Starting...
GPU Device 0: "Kepler" with compute capability 3.5

MatrixA(4096,256), MatrixB(256,4096)
Computing result using CUDA Kernel...
done
Performance= 312.00 GFlop/s, Time= 1.721 msec, Size= 536870912 Ops,
WorkgroupSize= 1024 threads/block
Checking computed result for correctness: Result = PASS
```



Executar exemplo de multiplicação de matrizes

```
$ srun -p nvidia_dev ./matrixMul -wA=8192 -hA=256 -wB=256 -hB=8192
srun: job 10857667 queued and waiting for resources
srun: job 10857667 has been allocated resources
[Matrix Multiply Using CUDA] - Starting...
GPU Device 0: "Kepler" with compute capability 3.5

MatrixA(8192,256), MatrixB(256,8192)
Computing result using CUDA Kernel...
done
Performance= 306.13 GFlop/s, Time= 3.507 msec, Size= 1073741824 Ops,
WorkgroupSize= 1024 threads/block
Checking computed result for correctness: Result = PASS
```

